

불법 수상정 포획을 위한 강화학습 기반 무인수상정 협력 제어

Multi-Agent Reinforcement Learning for Cooperative Unmanned Surface Vehicle Control in Illegal Vessel Capture

^{id}윤 영 준⁺, ^{id}방 현 태⁺, ^{id}최 경 원^{id}, 윤 원 준^{id}

(Youngjun Yun^{1,+}, Hyuntac Bang, Kyungwon choi, and Wonkeun Youn^{1,*})

¹Department of Autonomous Vehicle System Engineering Chungnam National University

Abstract: This paper proposes a cooperative capture system in which two allied ships jointly deploy a capture net to intercept an enemy vessel approaching a mothership, trained using multi-agent reinforcement learning (MARL). The maritime simulation environment is built on the Unity engine with Gerstner wave and wind disturbance models to reflect realistic sea conditions. Each agent employs an ego-centric polar coordinate observation space, where distance observations are normalized using a bounded rational function that maintains high resolution at close range while saturating at far distances, and angular observations are transformed via trigonometric functions to eliminate boundary discontinuities. The MA-POCA (Multi-Agent POsthumous Credit Assignment) algorithm with CTDE (Centralized Training with Decentralized Execution) architecture is adopted, enabling cooperative strategy learning during training while allowing decentralized execution using only local observations. The reward structure employs a raycast-based interception reward, where rays are cast from the enemy toward the mothership and agents receive dense rewards for positioning their capture net across these threat lines, combined with sparse event rewards for capture success. Experimental results in the simulated environment demonstrate that the proposed approach enables the two ships to learn coordinated net-based capture maneuvers under varying sea conditions.

Keywords: unmanned surface vehicles (USVs), Multi-Agent Reinforcement Learning(MARL), Cooperative Capture, Maritime Simulation

1. 서론

불법·비보고·비규제(IUU) 어선 단속, 해상 밀수 차단, 해양보호구역 침범 선박 제지 등 해상 내 비협조 선박을 저지해야 하는 수요는 민간 해양 경비와 군사 방어 양측에서 지속적으로 증가하고 있다. 또한 군사적으로는 자폭선과 같은 무인 수상정의 공격이 새로운 위협으로 대두되면서, 해당 선박들에 대한 무력화 방법에 관한 연구는 필수적이다. 이때 요격과 같은 물리적 파괴로의 저지는 많은 인명적·재물적 비용이 발생한다. 또한 유인 선박으로의 접근 후 포획은 해당 탑승자의 안전을 보장할 수 없는 문제가 존재한다. 차단망을 공유하는 두 대의 수상정이 특정 선박을 포획하는 방식은 화력에 의존하지 않는 비살상 물리적 차단 수단이다. 이와 같은 방식은 인명 피해 없이 대상 선박의 추진기관을 무력화할 수 있어 민간 해역에서도 적용 가능한 경제적인 제압 방법이다. 그러나 이러한 협력 포획 과제는 두 에이전트 간의 정교한 협력 기동, 차단망의 기하학적 제약, 그리고 해양 환경의 불확실성이라는 복합적인 도전 과제가 존재한다.

전통적인 규칙 기반(Rule-based) 접근법은 사전 정의된

시나리오에서는 효과적이거나, 파도와 바람에 의한 외란, 위협 선박의 가변적인 접근 경로, 그리고 실시간 협력 조율에 유연하게 대응하기 어렵다는 한계가 있다. 이에 반해 심층 강화학습(Deep Reinforcement Learning)은 복잡한 의사결정 문제의 유력한 해결 방안으로 주목받고 있으며 [2], 자율 운항 선박의 충돌 회피 [3]와 무인 수상정의 경로 계획 [4] 등 해상 환경에서의 효용성이 입증된 바 있다. 특히 다중 에이전트 강화학습(MARL)은 협력적 과제에서 에이전트 간의 상호작용을 자동으로 학습할 수 있어 [5, 6], 무인수상정 관련 연구에서도 널리 사용되고 있는 추세이다. 기존 연구에서는 장애물 회피, 군집 선박 대형 유지 등 개별 과제에 대한 성과가 보고되었으나, 차단망이라는 물리적 구속 조건 하에서 특정 대상을 포획하는 문제를 다중 에이전트 강화 학습으로 해결한 연구는 아직 활성화되지 않은 상황이다.

본 논문의 주요 기여는 다음과 같다. 첫째, 외란을 포함한 사실적 해상 시뮬레이션 환경을 구축하고, 이를 기반으로 협력 포획 학습 프레임워크를 제안한다. 둘째, 자기중심 극좌표 관측 체계와 다양한 거리 범위와 각도 불연속 문제를 효과적으로 해결하는 관측 공간 설계 방법을 제시한다. 셋

+These authors contributed equally to this work

*Corresponding Author

Manuscript received 20xx.xx.xx; revised 20xx.xx.xx; accepted 20xx.xx.xx

윤영준: 충남대학교 자율운항시스템공학과 석사과정

방현태: 충남대학교 자율운항시스템공학과 박사과정(htbang@gnu.ac.kr, ORCID^{id} 0000-0002-2846-6334)

최경원: 충남대학교 자율운항시스템공학과 석사과정

윤원근: 충남대학교 자율운항시스템공학과 조교수(wkyoun@cnu.ac.kr, ORCID^{id} 0000-0001-6954-9059)

※ 이 연구는 2025년 정부(방위사업청)의 재원으로 국방과학연구소의 지원을 받아 수행된 미래도전국방기술 연구개발사업임 (No.915141301)

Copyright© ICROS 2025

제, MA-POCA 기반 CTDE 구조를 적용하여, 두 아군 USV가 차단망을 공유하며 협력 포획 기동을 자율적으로 학습할 수 있음을 검증한다.




그림 1. 물리 환경 시뮬레이션을 포함한 에이전트 상호작용 루프

Fig. 1. The Loop of Agent Interaction within the Physics Simulation Environment

II. 포획 시스템




Fig. 2. 차단망을 이용한 협력 포획 시스템

Fig. 2. Cooperative capture system using a capture net.

본 연구에서 제안하는 불법 선박 포획 방식은 Fig. 2와 같이 두 대의 아군 선박이 편대를 이루어 선박 사이에 전개한 차단망으로 적군 선박을 포획하는 협력 기동 방식이다. 두 선박은 차단망의 물리적 길이에 맞추어 선박 간 유클리드 거리를 실시간으로 조정하며, 차단망의 기하학적 전개 한계를 고려한 협력 기동을 수행한다.

차단망은 두 선박의 실시간 위치에 따라 동적으로 형상이 변화하며, 선박 간 거리에 비례하여 차단망의 유효 전개

폭이 결정된다. 선박 간 거리가 최소 활성화 거리 이상일 때 차단망은 충분한 장력을 확보하여 유효한 포획력을 갖추게 되며, 이 상태에서 적군 선박과의 접촉 시 포획이 성립한다. 반대로, 선박 간 거리가 최소 활성화 거리 미만으로 좁혀지면 차단망이 충분한 장력을 갖추지 못하여 포획 기능이 비활성화된다. 이는 실제 해상 환경에서 차단망이 일정 수준 이상 전개되어야만 유효한 차단 및 포획이 가능하다는 물리적 제약을 반영한 것이다.

III. 시뮬레이션 환경 구성

1. 훈련 환경 구성

ML-Agents 기반의 강화학습 환경을 위해 Unity 엔진을 활용하여 해상 시뮬레이터를 구축한다. 해당 시뮬레이터는 방어 대상인 모선, 이를 방어하는 아군 선박 2대, 그리고 모선을 향해 접근하는 적군 선박으로 구성된다. 아군 선박 2대는 선박 사이에 전개한 그물을 이용하여 적군 선박이 모선에 도달하기 전에 이를 포획하는 것을 목표로 한다.



Fig. 3. 구현된 아군 USV(좌) 및 포획 대상 USV(우) 3D 모델.

Fig. 3. 3D models of the implemented defending USV (left) and invading USV (right).

실제 해상 환경에서는 불법 조업 선박, 밀수선, 무인 자폭정 등 다양한 유형의 위협 선박이 존재하며, 각 상황에 따라 요구되는 대응 방식이 상이하다. 본 연구에서는 이 가운데 가장 위협도가 높고 대응 시간이 제한적인 시나리오인 자폭 선박의 모선 돌진 상황을 대상으로 환경을 설정하였다. 자폭 선박은 모선을 향해 최단 경로로 고속 접근하며, 아군은 제한된 시간 내에 협력 기동을 통해 이를 차단 및 포획해야 한다.



Fig. 4. Unity 기반 해상 시뮬레이터

Fig. 4. Unity-Based Maritime Simulator




Fig. 4. 포획 실패 시 자폭 선박의 폭발

Fig. 4. Detonation of a suicide vessel upon capture failure.

2. 외란 구현

해양 물리 시뮬레이션은 Unity BoatAttack 오픈소스 프로젝트[참조]의 Gerstner 파랑 모델을 기반으로 구현하였다. Gerstner 파 이론은 다중 파형의 합성을 통해 해수면 변위를 계산하며, 각 파형의 각진동수는 분산 관계로부터 식 (1)과 같이 결정된다.

$$\omega_i = \frac{2\pi}{\lambda_i}, \quad c_i = \sqrt{g \cdot \omega_i} \quad \left(\begin{array}{l} \omega_i : \text{angular frequency}, \lambda_i : \text{wavelength}, \\ c_i : \text{phase velocity}, g : \text{gravitational acceleration} \end{array} \right) \quad (1)$$

파형의 첨예도를 제어하는 Gerstner Q 계수는 식 (2)와 같이 정의된다.

$$Q_i = \frac{Q_{peak}}{A_i \cdot \omega_i \cdot N} \quad \left(\begin{array}{l} Q_i : \text{Gerstner steepness factor}, A_i : \text{amplitude}, \\ N : \text{number of waves}, Q_{peak} : \text{peak sharpness constant} \end{array} \right) \quad (2)$$

임의의 수평 위치에서 파형의 위상과 수면 변위는 식 (3)-(4)로 계산된다.

$$\theta_i = \hat{d}_i \cdot p \cdot \omega_i - c_i \cdot t \quad \left(\begin{array}{l} \theta_i : \text{phase}, \hat{d}_i : \text{wave propagation direction}, \\ p : \text{horizontal position}, t : \text{time} \end{array} \right) \quad (3)$$

$$\left(\begin{array}{l} \Delta x = \sum_{i=1}^N Q_i A_i \hat{d}_{i,x} \cos \theta_i, \\ \Delta z = \sum_{i=1}^N Q_i A_i \hat{d}_{i,z} \cos \theta_i \end{array} \right)$$

$$(\Delta x, \Delta z : \text{horizontal displacement}) \quad (4)$$

식 (5)는 파형에 의한 수평 변위로, Gerstner 파 고유의 궤도 운동을 재현하며, 식 (5)는 각 파형의 수직 기여를 파형 수로 정규화하여 합산한 것이다. 이를 통해 복수의 파형이 중첩되더라도 해수면 높이가 비현실적으로 증폭되지 않도록 한다.

$$\Delta y = \sum_{i=1}^N \frac{A_i}{N} \sin \theta_i \quad (\Delta y : \text{vertical displacement}) \quad (5)$$

선체에 작용하는 풍력은 매 물리 스텝마다 식 (6)과 같이 계산되어 선체에 직접 적용되도록 추가 구현을 하였다.

$$\mathbf{F}_{wind} = \hat{d}_{wind} \cdot S_{wind} \cdot K_{mul} \cdot K_{env} \quad (6)$$

$$\left(\begin{array}{l} \hat{d}_{wind} : \text{wind direction}, S_{wind} : \text{wind speed}, \\ K_{mul} : \text{force multiplier}, K_{env} : \text{environmental sensitivity} \end{array} \right)$$

Gerstner 파랑 모델과 풍력 모델의 파라미터들은 매 에피소드 시작 시 무작위로 설정된다. 이를 통해 에이전트는 단일 학습 과정 내에서 풍향과 파향의 다양한 조합에 따른 복합적인 외란 패턴에 노출되며, 다양한 해상 환경을 경험하게 된다. 이러한 도메인 랜덤화 전략은 학습된 정책이 특정 해상 조건에 과적합되는 것을 방지하는 동시에, 실패역에서 발생할 수 있는 다양한 외란 조건에 대한 강건성을 확보하여 시뮬레이션과 실험상 간의 전이 가능성을 높이고자 하였다.

IV. 모델 구성

2대의 선박이 그물을 이용하여 적군을 포획하기 위해서는 각 선박의 독립적인 조종과 동시에 상호 간의 긴밀한 협력 기동이 요구된다. 이를 위해 본 연구에서는 다중 에이전트 강화학습(Multi-Agent Reinforcement Learning, MARL) 방식을 채택하였다.




Fig. 5. MA-POCA 기반 협동 학습 구조

Fig. 5. MA-POCA-based cooperative learning architecture.

학습 알고리즘으로는 MA-POCA(Multi-Agent Posthumous Credit Assignment)를 적용하였다. MA-POCA는 Fig. 5와 같이 CTDE(Centralized Training with Decentralized Execution) 구조를 따른다. 학습 시에는 중앙 집중형 비평가(Centralized Critic)가 모든 에이전트의 관측을 Attention/Pooling 계층으로 통합하여 팀 전체의 가치 함수 $V(s)$ 를 추정하고, 이를 통해 팀 보상을 각 에이전트의 기여도에 따라 사후적으로 귀속한다. 실행 시에는 각 에이전트가 자신의 관측만을 이용하여 독립적으로 행동을 결정하므로, 중앙 통신 없이도 분산 실행이 가능하다. 이러한 구조는 학습 시에는 팀 전체의 정보를 활용하여 협동 전략을 효과적으로 학습하면서도, 실제 운용 시에는 학습 때보다 더 한정적인 정보로의 분산 실행이 가능하다는 이점을 갖는다.




Fig. 6. LSTM 기반 정책 네트워크 구조

Fig. 6. LSTM-based policy network architecture

앞서 기술한 MA-POCA의 CTDE 구조가 팀 전체의 학습 프레임워크를 정의한다면, 각 아군 선박의 개별 정책 네트워크는 Fig. 5와 같은 구조를 따른다. 개별 에이전트는 파트너 선박의 상대 위치 및 차단망 전개 길이, 적군 선박의 상대 거리·방위각·헤딩, 모선과의 거리 정보를 관측으로 입력받으며, 이를 LSTM(Long Short-Term Memory) 기반 순환 신경망을 통해 처리한다.

LSTM을 적용한 이유는 적군 선박의 포획이 단일 시점의 관측만으로는 달성하기 어려운 시계열적 판단을 요구하기 때문이다. 적군 선박의 접근 속도 및 방향 변화, 파트너 선박과의 상대적 위치 변화 등 시간에 따른 상태 변화를 기억함으로써, 에이전트는 적군의 향후 경로를 예측하고 이에 맞춘 선제적 차단 기동을 수행할 수 있다.

LSTM의 출력은 2개의 완전연결층(Fully Connected Layer)을 거쳐 최종적으로 추력(throttle)과 조타(steering)의 2차원 연속 행동으로 변환된다. 학습에 사용된 주요 하이퍼파라미터는 Table 1과 같다.

표. 1. 개별 에이전트 정책 네트워크 구성

Table 1. Individual agent policy network configuration

Parameter	Value
Hidden units	256
Num layers	2
Memory size	128
Sequence length	64

V. 관측값 구성

Fig. 7. 자기 중심 극좌표 관측 구조

Fig. 7. Ego-centric polar coordinate observation structure

각 에이전트는 자기 중심(ego-centric) 극좌표계(거리, 방위각) 기반으로 환경을 관측한다. 절대 좌표를 사용할 경우 동일한 상대적 상황이라도 위치에 따라 관측값이 달라져 학습의 일반화 성능이 저하되므로, 모든 관측값은 자기 선박의 위치와 헤딩을 기준으로 한 상대 극좌표로 변환된다. 이를 통해 거리와 방향이 직관적으로 분리되며 회전 불변성이 확보된다. 관측 대상은 적군 선박, 파트너 선박, 모선의 세 가지로 구성되며, 각 관측값의 상세 구성은 Table 2와 같다.

NED frame




표. 2. 에이전트 관측 공간 구성

Table 2. Agent observation space configuration

Target	Observation	Raw Range
Partner ship	Distance	1 - 50 m
	Relative bearing	-180° - 180°
	Relative heading	-180° - 180°
Enemy ship	Distance	0 - 5000 m
	Relative bearing	-180° - 180°
	Relative heading	-180° - 180°

Table 2에서 확인할 수 있듯이, 원시 관측값은 파트너 선박과의 거리가 최대 50m인 반면 적군 선박과의 거리는 최대 5,000m에 달하는 등 범위의 차이가 크며, 각도 관측값은 $\pm 180^\circ$ 경계에서 불연속이 발생한다. 특히 거리 범위의 불균형은 신경망이 절댓값이 큰 적군 거리에 편향되어, 실제로는 동등하게 중요한 파트너 선박과의 근접 기동 정보가 상대적으로 경시되는 문제를 야기할 수 있다. 이를 해결하기 위해 모든 관측값에 유계 정규화 함수를 적용하여 $[-1, +1]$ 범위로 변환하였다.

거리값에는 식 (7)을 대입하여 근거리에서의 변화가 더 중요한 포획 환경에 맞게 작은 값일수록 큰 변화율이 생기도록 전처리한다.

$$f(dist) = \frac{dist}{|dist| + k} \quad (7)$$

이때 K값을 포획 선박과 협력 선박을 관측할 때를 다르게 설정함으로써 포획 선박을 관측할 시에는 먼 거리도 민감하게 볼 수 있게, 협력 선박을 관측할 시에는 가까운 거리를 더 민감하게 보도록 설정한다.




Fig. 8. 관측 대상별 거리 감도 조정

Fig. 8. Distance Sensitivity Tuning by Observation Target

각도 관측값에는 삼각함수 기반 정규화를 적용하였다. 원시 각도값은 $\pm 180^\circ$ 경계에서 -180° 와 $+180^\circ$ 가 불연속적으로 전환되어, 물리적으로 유사한 방향임에도 관측값이 급격히 변화하는 문제가 존재한다. 이를 해결하기 위해 식 (8)와 같이 사인 함수를 적용하여 각도 차이를 $[-1, +1]$ 범위의 연속적인 값으로 변환하였다.

$$f(\Delta\theta) = \sin\left(\frac{\Delta\theta \cdot \pi}{180}\right) \quad (8)$$

해당 함수를 통해 각도 차이가 0에 가까울수록 미세한 각도 변화에 대한 관측 해상도가 높아진다. 이는 포획 기동시 적군 선박과의 정밀한 각도 정렬이 요구되는 상황에서 유리하게 작용한다. 특히 적군과의 상대 각도가 거의 정렬된 상태에서의 미세한 편차를 민감하게 감지할 수 있어, 에이전트가 최종 차단 위치로의 정밀 기동을 수행하는 데 기여한다.




Fig. 9. 각도 관측값의 삼각함수 정규화 전·후 비교

Fig. 9. Comparison of angular observation before and after trigonometric normalization

VI. 보상값 구성

보상 함수의 설계는 에이전트의 학습 방향을 결정짓는 핵심 요소이다. 보상체계는 기하학적 관계에 기반한 연속 보상과 임무 결과에 기반한 순간 보상을 계층적으로 결합하였다. 우선 연속 보상의 구성 요소는 아래 네 가지 요소와 같다.

1. 대형 유지 보상

두 아군 선박 간 거리 d_{ally} 가 최적 거리 d_{opt} 기준 허용 범위 이내일 때, 오차에 반비례하는 보상을 부여한다.

$$r_{formation} = \alpha_f \times \left(1 - \frac{|dist_{pair} - dist_{ref}|}{\delta}\right) \quad (9)$$

2. 적 접근 보상

그물 중심과 가장 가까운 활성 적군 간의 유클리드 거리 변화량을 측정하여, 접근 시 양의 보상을 부여한다.

$$r_{approach} = \alpha_a \times \max(dist_{enemy}^{t-1} - dist_{enemy}^t, 0) \quad (10)$$

3. 선수 정렬 보상

각 에이전트의 진행 방향 벡터와 가장 가까운 적군으로의 방향 벡터 간 내적을 개별 보상으로 부여한다.

$$r_{heading} = \alpha_h \times \max(\cos\theta_{enemy}, 0) \quad (11)$$

4. 시간 벌점

매 스텝 벌점을 그룹 전체에 부과하여, 불필요한 지연 없이 신속한 차단 및 포획을 유도한다.

$$r_{time} = -0.0001 \quad (12)$$

특정한 사건이 발생할 때만 부여되는 순간 보상에 대해서는 아래의 표 3과 같다. 포획 성공 시의 보상과 모션 피격·아군 충돌 시에는 각각 벌점의 부과와 함께 에피소드는 조기 중단되게 된다. 모든 순간 보상은 에피소드 종료와 동시에 발생하므로, 에이전트는 성공과 실패를 즉각적으로 구분할 수 있어 목표 지향적인 행동을 학습하게 된다.

표. 3. 순간 보상 구성

Table. 3. Instantaneous Reward Configuration

사건	보상
포획 성공	+1.0
공격 허용	-1.0
아군끼리의 충돌	-1.0

이러한 계층적 보상 구조는 최종 목표인 불법선박 포획이라는 최소한 순간 보상에 도달하기까지의 탐색 공간을 연속 보상을 통해 점진적으로 축소한다. 대형 유지·적 접근·선수 정렬의 연속 보상이 매 스텝 학습 경사를 제공함으로써, 에이전트는 보상이 부재한 초기 학습 단계에서도 포획에 유리한 전술적 상태로 수렴할 수 있다.

VII. 학습 결과

1. 학습 과정

본 연구에서는 학습 효율을 극대화하기 위해 Unity ML-Agents의 병렬 환경 인스턴스를 활용하였다. 동일한 방 어 시나리오를 복수의 환경에서 동시에 시뮬레이션하여, 각 환경이 독립적으로 에피소드를 진행하면서 경험 데이터를 공유 정책 네트워크에 공급한다. 이를 통해 단일 환경 대비 경험 수집 속도를 환경 수에 비례하여 증가시키게 된다.




Fig. 9. 다중 환경 인스턴스를 활용한 병렬 학습 구조

Fig. 9. Parallel Training Architecture with Multiple Environment Instances

학습에 사용된 MA-POCA 알고리즘의 주요 하이퍼파라미터는 Table 3과 같다. 학습률은 선형 감소 스케줄을 적용하여 학습 초기에는 빠른 탐색을, 후기에는 안정적인 수렴을 유도하였다. 정책 네트워크는 256개 은닉 유닛의 2층 완전 연결 구조로 구성하였으며, 관측값 정규화를 활성화하여 서로 다른 스케일의 입력 특성을 균일하게 처리하도록 하였다.

표. 3. MA-POCA 학습 하이퍼파라미터

Table 3. MA-POCA training hyperparameters

Parameter	Value
Batch size	1024
Buffer size	20480
Learning rate	0.0003
Beta (entropy)	0.005
Epsilon (clip)	0.2
Lambda (GAE)	0.95
Num epoch	3
LR schedule	Linear
Gamma	0.995
Strength	1




Fig. 10. 보상 수렴 그래프

Fig. 10. Reward Convergence




Fig. 11. 그룹 보상 수렴 그래프

Fig. 11. Group Reward Convergence




Fig. 12. 가치 손실 수렴 그래프

Fig. 12. Value Loss Convergence

Fig. 10~12는 학습 과정에서의 보상 및 손실 추이를 나타낸다. 개별 보상과 그룹 보상 모두 학습 초기에는 무작위 기동으로 인해 낮은 값을 보이나, 학습이 진행됨에 따라 연속 보상의 유도 효과에 의해 점진적으로 상승하며 안정적으로 수렴하는 것을 확인할 수 있다. 개별 보상의 수렴은 각 에이전트가 선수 정렬 등 독립적 행동 목표를 달성하였음을 의미하며, 그룹 보상의 수렴은 대형 유지와 적 접근이라는 협력적 행동이 안정적으로 형성되었음을 나타낸다. Fig. 12의 가치 손실은 학습이 진행됨에 따라 지속적으로 감소하여 수렴하였으며, 이는 가치 네트워크의 상태 가치 추정이 안정화되었음을 의미한다. 보상의 수렴과 가치 손실의 동시 감소는 정책과 가치 함수가 균형 있게 학습되었음을 보여준다.

2. 학습 결과

학습된 모델의 성능을 정량적으로 평가하기 위해, 강화 학습 기반 정책과 LOS(Line-of-Sight) Guidance 기반 정책을 시뮬레이션 환경에서 비교 실험하였다. 기존의 LOS Guidance는 복수의 고정 경유점(Waypoints)을 순차적으로 추종하는 방식이나, 본 시스템에서는 포획 대상이 모선에 충돌하기 전에 포획을 해야한다는 상황에 따라 각 지점들이 고정이 되어있지 않기 때문에 방어 대상과 포획 대상의 상대 좌표 관계를 직접 활용하는 수정된 LOS 로직을 적용하였다. 해당 방식을 통해 변화하는 두 개체 사이의 가상 경로를 실시간으로 생성함으로써 포획 대상까지의 효율적

인 경로로 다가갈 수 있도록 구현하였다.

NED Frame




Fig. 10. 동적 타겟 포획을 위한 적응형 LOS Guidance

Fig. 10. Modified LOS Guidance for Dynamic

이때 비교군이 되는 LOS Guidance는 다음과 같은 방식과 파라미터로 진행된다. LOS Guidance는 고전적 항법 알고리즘을 협력 그물 포획 시나리오에 맞게 변형한 규칙 기반 조향 알고리즘이다. 각 아군 선박은 적군 위치와 모선 위치를 잇는 위협 방향 단위 벡터를 산출한 뒤, 이에 수직인 횡방향 단위 벡터를 산출한다.

$$\hat{d} = \frac{p_m - p_e}{\|p_m - p_e\|} \left\{ \begin{array}{l} p_m : \text{mothershipposition}, p_e : \text{enemyposition}, \\ \hat{d} : \text{unitvectorfromenemytomothership} \end{array} \right\} \quad (12)$$

두 아군 선박은 그물 전개를 위해 적군 전방 선행 지점에서 좌우로 분리된 목표 지점을 추종하며, 목표 지점은 다음과 같이 정의된다.

$$p_{\text{target}} = p_e + d_{\text{lead}} \cdot \hat{d} + s \cdot d_{\text{spread}} \cdot \hat{n} \quad (13)$$

$$\left\{ \begin{array}{l} p_{\text{target}} : \text{waypoint}, d_{\text{lead}} = \text{leaddistance}, \\ d_{\text{spread}} = \text{preaddistance}, s = +1(\text{left}) \text{ or } -1(\text{right}) \end{array} \right\}$$

목표 지점이 산출되면 현재 heading과 목표 방향 간의 방위각 오차에 대해 PD 제어를 적용하여 조향 입력을 생성한다. P gain=3, D gain=0.5를 적용한다.

$$\delta_{\text{steer}} = \text{clamp}(K_p \frac{\beta}{180} + K_d \frac{\beta - \beta_{\text{prev}}}{180}, -1, 1)$$

$$\left\{ \begin{array}{l} \delta_{\text{steer}} : \text{steeringinput}, K_p = 3.0, K_d = 0.5 \\ \beta : \text{bearingerror(deg)}, \beta_{\text{prev}} : \text{previousstepbearingerror}, \end{array} \right\} \quad (14)$$

속력은 목표 지점까지의 거리에 따라 선형 보간하여 포획 대상과의 거리가 가까워질수록 속도가 낮아지도록 제어한다.

$$\tau = \tau_{\min} + (\tau_{\max} - \tau_{\min}) \cdot \frac{r}{d_{\text{approach}}} \quad (r \leq d_{\text{approach}})$$

$$\left\{ \begin{array}{l} \tau : \text{throttleoutput}, \tau_{\max} = \text{max input}, \tau_{\min} = \text{min input}, \\ d_{\text{approach}} = \text{decelerationrange}, r : \text{distancetowaypoint} \end{array} \right\} \quad (14)$$

두 정책 모두 동일한 조건하에 각각 40회의 에피소드를

수행하였으며, 각 정책에 따른 방어 궤적과 포획 여부는 아래의 Fig 10과 Fig 11과 같다.




Fig. 10. LOS 가이드نس 기반 방어 궤적 및 포획 결과

Fig. 10. Defense Trajectories and Capture Results Based on LOS Guidance




Fig. 10. 강화학습 모델 기반 방어 궤적 및 포획 결과

Fig. 10. Defense Trajectories and Capture Results Based on RL Model Inference

각각의 성능에 대한 평가를 위하여 몇 가지 기준으로의 비교를 한다. 성능 대한 평가지표들은 표 (4)에서의 지표로 진행하고, 해당 지표들의 성능은 표 5와 같다.

표. 4. 성능 평가 지표

Table 4. Performance Evaluation Metrics

평가 지표	평가 요소
포획률	적군 선박이 포획된 비율
공격 허용률	적군 선박이 방어선을 돌파하여 공격에 성공한 비율
대형 붕괴율	아군 선박끼리의 충돌이나 아군 선박 간의 거리가 그물의 길이를 초과한 비율

표. 5. 제어 방식별 방어 성능 비교

Table 5. Defense Performance Comparison by Control Method

평가 지표	LOS Guidance	RL 정책
포획률	6/40 (15.0%)	26/40 (65.0%)
공격 허용률	25/40 (62.5%)	11/40 (27.5%)
대형 붕괴율	9/40 (22.5%)	3/40 (7.5%)




Fig. 10. 강화학습 모델 기반 방어 궤적 및 포획 결과

Fig. 10. Defense Trajectories and Capture Results Based on RL Model Inference

표 5의 결과와 Fig10에서 확인할 수 있듯이, 강화학습 기반 정책은 기존 LOS 유도 방식 대비 모든 평가 지표에서 유의미한 성능 향상을 보였다. 포획률의 경우, LOS 유도 방식이 15.0%에 그친 반면, 강화학습 정책은 65.0%를 달성하여 약 4.3배의 성능 개선을 나타냈다. 공격 허용률 또한 LOS 유도 방식의 62.5%에서 27.5%로 대폭 감소하여, 적군 선박의 방어선 돌파를 효과적으로 억제함을 확인하였다. 특히 대형 붕괴율은 22.5%에서 7.5%로 약 3배 감소하였는데, 이는 강화학습 정책이 단순히 포획 성공률을 높이는 것에 그치지 않고, 아군 선박 간의 협조적 기동을 통해 대형을 안정적으로 유지하면서도 효과적인 방어 임무를 수행할 수 있음을 의미한다. 이러한 결과는 LOS 유도 방식과 같은 사전 정의된 경로 추종 기반 제어가 동적으로 변화하는 적군의 기동에 능동적으로 대응하기 어려운 반면, 강화학습 기반 정책은 실시간으로 상황에 맞는 최적의 행동을 선택함으로써 복합적인 방어 목표를 동시에 달성할 수 있음을 확인하였다.

VIII. 결론

본 연구는 해양 환경에서 두 척의 아군 선박이 그물을 공유하여 불법선박 한 대를 협력적으로 포획하는 문제에 대해, MA-POCA 기반의 다중 에이전트 강화학습 접근법을 제안하였다. Gerstner 파도 모델과 풍하중이 작용하는 사실적 해양 시뮬레이션 환경을 구축하고, 자기중심 극좌표 관측 체계와 유리유계 정규화 함수를 통해 에이전트의 관측 공간을 설계하였다. 보상체계는 대형 유지·적 접근·선수 정렬의 연속 보상과 포획 성공·방어 실패의 순간 보상을 계층적으로 결합하여, 희소한 최종 목표까지의 탐색 공간을 점진적으로 축소하였다.

학습 결과, 개별 보상과 그룹 보상이 모두 안정적으로 수렴하였으며, 가치 손실의 동시 감소를 통해 정책과 가치 함수의 균형 있는 학습이 이루어졌음을 확인하였다. 이는

MA-POCA의 크레딧 할당 메커니즘이 각 에이전트의 개별 기여와 협력적 기여를 효과적으로 분리하여 학습할 수 있음을 실증적으로 보여준다. 또한, 학습된 강화학습 정책을 기존 LOS 유도 방식과 동일한 시뮬레이션 환경에서 비교 평가한 결과, 포획률과 대형 붕괴율은 대폭 개선하면서 실시간 상황 인식을 통해 대형 유지와 포획이라는 복합 목표를 동시에 달성할 수 있음을 입증하였다.

향후 연구에서는 다수의 적군 선박과 복수의 아군 쌍이 동시에 작전하는 가변적 상황으로 확장하여, 동적으로 변화하는 위협에 대응하는 군집 제어 문제를 다룰 예정이다. 나아가 Self-Play 구조를 도입하여 적군 선박에도 독립적인 회피 정책을 학습시킴으로써, 아군과 적군의 정책이 상호 경쟁적으로 진화하는 적대적 학습 환경을 구현하고자 한다. 이를 통해 사전에 정의된 적군 행동에 의존하지 않는, 보다 강건하고 일반화된 포획 전략의 도출이 가능할 것으로 기대된다.